

PL.

Пусть  $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ , где  $x \in \mathbb{R}^n$

$$\frac{\partial g}{\partial x} = \begin{pmatrix} \frac{\partial g_1}{\partial x_1} & \frac{\partial g_1}{\partial x_2} & \dots & \frac{\partial g_1}{\partial x_n} \\ \vdots & & & \vdots \\ \frac{\partial g_m}{\partial x_1} & \dots & \frac{\partial g_m}{\partial x_n} \end{pmatrix}$$

D. л. о. 1)  $a^T x = (a_1 \dots a_n) \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} = a_1 x_1 + \dots + a_n x_n$

$$\sum_{i=1}^n a_i x_i$$

$$\frac{\partial (a^T x)}{\partial x} = \begin{pmatrix} \frac{\partial (\sum_{i=1}^n a_i x_i)}{\partial x_1} \\ \frac{\partial (\sum_{i=1}^n a_i x_i)}{\partial x_2} \\ \vdots \\ \frac{\partial (\sum_{i=1}^n a_i x_i)}{\partial x_n} \end{pmatrix} = \begin{pmatrix} a_1 \\ \vdots \\ a_n \end{pmatrix} = a.$$

2)  $A = \begin{pmatrix} a_{11} & \dots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \dots & a_{mn} \end{pmatrix}$   $x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$   $Ax = \begin{pmatrix} \sum_{i=1}^n a_{1i} x_i \\ \sum_{i=1}^n a_{2i} x_i \\ \vdots \\ \sum_{i=1}^n a_{ni} x_i \end{pmatrix}$

$$\frac{\partial (Ax)}{\partial x} = \begin{pmatrix} \frac{\partial (\sum_{i=1}^n a_{1i} x_i)}{\partial x_1} & & & \\ & \frac{\partial (\sum_{i=1}^n a_{2i} x_i)}{\partial x_2} & & \\ & & \ddots & \\ & & & \frac{\partial (\sum_{i=1}^n a_{ni} x_i)}{\partial x_n} \end{pmatrix} = \begin{pmatrix} a_{11} & \dots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \dots & a_{mn} \end{pmatrix} = A.$$

3)  $x^T Ax = \left( \sum_{i=1}^n a_{ij} x_i \right) \left( \sum_{j=1}^n a_{ij} x_j \right) = \sum_{j=1}^n \sum_{i=1}^n a_{ij} x_i x_j.$

$$\frac{\partial (x^T Ax)}{\partial x} = \frac{\partial \left( \sum_{j=1}^n \sum_{i=1}^n a_{ij} x_i x_j \right)}{\partial x} = \begin{pmatrix} 2a_{11} x_1 + \sum_{i \in \{2, \dots, n\}} a_{1i} x_i + \sum_{j \in \{2, \dots, n\}} a_{1j} x_j \\ \vdots \\ 2a_{nn} x_n + \sum_{i \in \{1, \dots, n-1\}} a_{ni} x_i + \sum_{j \in \{1, \dots, n-1\}} a_{nj} x_j \end{pmatrix} =$$

$$= \begin{pmatrix} \sum_{i=1}^n x_i (a_{1i} + a_{i1}) \\ \vdots \\ \sum_{i=1}^n x_i (a_{ni} + a_{in}) \end{pmatrix} = (A + A^T)x$$

4)  $\|x\|^2 = x_1^2 + x_2^2 + \dots + x_n^2$   $\frac{\partial \|x\|^2}{\partial x} = \begin{pmatrix} 2x_1 \\ \vdots \\ 2x_n \end{pmatrix} = 2x$

5)  $g(x) = \begin{pmatrix} g(x_1) \\ \vdots \\ g(x_n) \end{pmatrix}$   $\frac{\partial g(x)}{\partial x} = \begin{pmatrix} \frac{\partial g(x_1)}{\partial x_1} & \frac{\partial g(x_1)}{\partial x_n} \\ \vdots & \vdots \\ \frac{\partial g(x_n)}{\partial x_1} & \frac{\partial g(x_n)}{\partial x_n} \end{pmatrix} = \begin{pmatrix} g'(x_1) & 0 & \dots & 0 \\ 0 & g'(x_2) & 0 & \dots \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & g'(x_n) \end{pmatrix} = \text{diag}(g'(x)).$

$$6) \frac{\partial g(h(x))}{\partial x} = \begin{pmatrix} \frac{\partial g_1(h(x))}{\partial x_1} & \dots & \frac{\partial g_1(h(x))}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_p(h(x))}{\partial x_1} & \dots & \frac{\partial g_p(h(x))}{\partial x_n} \end{pmatrix} = \begin{pmatrix} \frac{\partial g_1(h(x))}{\partial h_1} & \dots & \frac{\partial g_1(h(x))}{\partial h_m} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_p(h(x))}{\partial h_1} & \dots & \frac{\partial g_p(h(x))}{\partial h_m} \end{pmatrix}.$$

$$\cdot \begin{pmatrix} \frac{\partial h_1(x)}{\partial x_1} & \dots & \frac{\partial h_1(x)}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial h_m(x)}{\partial x_1} & \dots & \frac{\partial h_m(x)}{\partial x_n} \end{pmatrix} = \frac{\partial g(h(x))}{\partial h} \cdot \frac{\partial h(x)}{\partial x}$$

N2

$$\text{Задача} \quad g(\beta) = \|X\beta - y\|^2 = (X\beta - y)^T(X\beta - y)$$

Производная:  $g(\beta) = \beta^T X^T \beta - 2y^T X\beta + y^T y$ ,  $y^T y$  не зависит от  $\beta$ .

Найдем производную по  $\beta$ :  $\frac{\partial}{\partial \beta} (\beta^T X^T X \beta) = ((X^T X + (X^T X)^T) \beta)$ , а  $(X^T X)^T = X^T X$

$$\text{значит производная } \frac{\partial}{\partial \beta} (\beta^T X^T X \beta) = 2X^T X \beta.$$

$$\frac{\partial}{\partial \beta} (-2y^T X\beta) = -2X^T y \Rightarrow \nabla g(\beta) = 2X^T X\beta - 2X^T y = 0 \quad X^T X\beta = X^T y$$

$$\beta = (X^T X)^{-1} X^T y. \quad \frac{\partial^2 g(\beta)}{\partial \beta \partial \beta^T} = \frac{\partial}{\partial \beta^T} \left( \frac{\partial g(\beta)}{\partial \beta} \right) = \frac{\partial}{\partial \beta^T} (2X^T X\beta - 2X^T y) = 2X^T X$$

~~N17~~ N17

$$X = \begin{pmatrix} 4 & 2 & 3 \\ 0 & -3 & 2 \\ -1 & -2 & 2 \\ 3 & 1 & 1 \\ 4 & 2 & -3 \end{pmatrix} \quad \bar{x}_1 = \frac{4+0+(-1)+3+4}{5} = 2 \\ \bar{x}_2 = \frac{2+(-3)+(-2)+1+2}{5} = 0 \quad \Rightarrow \quad \bar{X}^T = \begin{pmatrix} 2 & -2 & -3 & 1 & 2 \\ 2 & -3 & -2 & 1 & 2 \\ 2 & 1 & 1 & 0 & -4 \end{pmatrix}$$

$$\bar{x}_3 = \frac{3+2+2+1+(-3)}{5} = 1$$

Ковариационное ядро  $S = \frac{1}{n-1} \bar{X}^T \bar{X}$ .

$$X^T X = \begin{pmatrix} 22 & 21 & -9 \\ 21 & 22 & -9 \\ -9 & -9 & 22 \end{pmatrix} \quad S = \frac{1}{4} \begin{pmatrix} 22 & 21 & -9 \\ 21 & 22 & -9 \\ -9 & -9 & 22 \end{pmatrix} = \begin{pmatrix} 5.5 & 5.25 & -2.25 \\ 5.25 & 5.5 & -2.25 \\ -2.25 & -2.25 & 5.5 \end{pmatrix}$$

$$\text{Решим } \det(S - \lambda I) = 0 \quad \begin{vmatrix} 5.5 - \lambda & 5.25 & -2.25 \\ 5.25 & 5.5 - \lambda & -2.25 \\ -2.25 & -2.25 & 5.5 - \lambda \end{vmatrix} = 0$$

$$\det((-\lambda I) - (3.5-\lambda)(5.5-\lambda)^2 + 10.5(-2.25)^2 - (3.5-\lambda)(2(-2.25))^2 + (3.25)^2) = 0$$

$$\Leftrightarrow 12.25 - 53.0825\lambda + 10.5\lambda^2 - \lambda^3 = 0 \Leftrightarrow -(\lambda-1)(\lambda-4)(4\lambda-49)=0$$

$$\Rightarrow \lambda_1 = 0.25 \quad \text{так как } \lambda_1 = 0.25 \quad (S - 0.25I)V = 0 \quad \chi_1 = \chi_2, \chi_3 = 0$$

$$\lambda_2 = 4 \quad \text{так как } \chi_1 = -1, \chi_2 = 1; V_1 = \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix} \text{ и } V_1 = \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}$$

$$\lambda_3 = 4 : (S - 4I) = 0 \quad \chi_1 = \chi_2, \chi_3 = 3\chi_1. \quad \text{так как } \chi_1 = 1 \Leftrightarrow V_2 = \begin{pmatrix} 1 \\ 3 \\ 0 \end{pmatrix}$$

$$\lambda_3 = 12.25 : (S - 12.25I) = 0 \quad \chi_1 = \chi_2, \chi_3 = -1.5\chi_1. \quad \text{так как } \chi_1 = -3 \Leftrightarrow$$

$$\Rightarrow \chi_2 = -3, \chi_3 = 2 : V_3 = \begin{pmatrix} -3 \\ 2 \\ 2 \end{pmatrix}. \quad \frac{1}{N-1}\lambda_1 = \frac{1}{N-1}\delta_1^{\mu_2} = \frac{1}{16} = 0.0625$$

$$\frac{\lambda_1}{\lambda_1 + \lambda_2 + \lambda_3} \approx 0.015$$

$$\frac{1}{N-1}\lambda_2 = \frac{1}{N-1}\delta_2^{\mu_2} = 1$$

$$\frac{\lambda_2}{\lambda_1 + \lambda_2 + \lambda_3} \approx 0.24$$

$$\frac{1}{N-1}\lambda_3 = \frac{1}{N-1}\delta_3^{\mu_2} = \frac{49}{16}$$

Найдем минимум разложения матриц:

$$X_C = V\Sigma V^T \quad V = \begin{pmatrix} 1 & 1 & -3 \\ -1 & 1 & -3 \\ 0 & 3 & 2 \end{pmatrix} \quad \Sigma = \begin{pmatrix} \gamma_1 & 0 & 0 \\ 0 & \gamma_2 & 0 \\ 0 & 0 & \gamma_3 \end{pmatrix} = \begin{pmatrix} 0.5 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 3.5 \end{pmatrix}$$

$$V\Sigma = X_C V = \begin{pmatrix} 2 & 2 & 2 \\ -2 & -3 & 1 \\ 3 & -2 & 1 \\ 1 & 1 & 0 \\ 2 & 2 & -4 \end{pmatrix} \begin{pmatrix} 1 & 1 & -3 \\ -1 & 1 & -3 \\ 0 & 3 & 2 \end{pmatrix} = \begin{pmatrix} 0 & 10 & -8 \\ 1 & -2 & 17 \\ -1 & -2 & 17 \\ 0 & 2 & -6 \\ 0 & -8 & -20 \end{pmatrix} \quad \Sigma^{-1} = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 0.5 & 0 \\ 0 & 0 & 2/7 \end{pmatrix}$$

$$U^2 X_C V \Sigma^{-1} = \begin{pmatrix} 0 & 10 & -8 \\ 1 & -2 & 17 \\ -1 & -2 & 17 \\ 0 & 2 & -6 \\ 0 & -8 & -20 \end{pmatrix} \begin{pmatrix} 2 & 0 & 0 \\ 0 & 0.5 & 0 \\ 0 & 0 & 2/7 \end{pmatrix} = \begin{pmatrix} 0.5 & -10/7 \\ 2 & -1 & 34/7 \\ -2 & -1 & 34/7 \\ 0 & 1 & -12/7 \\ 0 & -4 & -40/7 \end{pmatrix}$$

$$\begin{matrix} x & 1 & 1 & 0 & 0 & -1 \\ y & 4 & 4 & 0 & 2 & 6 \end{matrix}$$

$$X = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & -1 & 1 \end{pmatrix}$$

$$2) f(x) = \beta_0 + \beta_1 x + \beta_2 x^2$$

$$X^T X = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 0 & 0 & -1 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & -1 & 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 & 1 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & -1 & 1 \end{pmatrix} = \begin{pmatrix} 5 & 1 & 3 \\ 1 & 3 & 1 \\ 1 & 3 & 1 \\ 1 & 3 & 1 \\ 3 & 1 & 3 \end{pmatrix}$$

$$X^T y = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 0 & 0 & -1 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & -1 & 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 4 \\ 4 \\ 0 \\ 2 \\ 6 \end{pmatrix} = \begin{pmatrix} 10 \\ 10 \\ 10 \\ 10 \\ 10 \end{pmatrix}$$

$$X^T X \beta = X^T y \Rightarrow \beta = \begin{pmatrix} 1 \\ -1 \\ 4 \\ 2 \\ 1 \end{pmatrix}$$

$$f(x) = 1 - x + 4x^2$$

$$3) \lambda = 1 \\ X^T X + \lambda I = \begin{pmatrix} 6 & 1 & 3 \\ 1 & 6 & 1 \\ 1 & 1 & 6 \end{pmatrix}$$

$$= \begin{pmatrix} 5 & 1 & 3 \\ 1 & 3 & 1 \\ 1 & 3 & 1 \end{pmatrix} + \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 6 & 1 & 3 \\ 1 & 4 & 1 \\ 1 & 4 & 1 \end{pmatrix}$$

$$(X^T X + \lambda I) \beta = X^T y \Rightarrow$$

$$\beta = \begin{pmatrix} 3/2 \\ -1/2 \\ 5/2 \end{pmatrix}$$

$$f(x) = 3/2 + \frac{1}{2}x + \frac{5}{2}x^2$$



Чтобы выбрать оптимальную для нас модель  $(Y|X=x) = \arg\max_y \Pr(Y=y|X=x)$ .

Рассмотрим линеаризующую функцию потерь  $L(a,y) = \begin{cases} 0, & a=y \\ 1, & a \neq y \end{cases}$

$$R(a|x) = \sum_y L(a,y) \Pr(Y=y|X=x) = \sum_{y \neq a} \Pr(Y=y|X=x) = 1 - \Pr(Y=a|X).$$

Минимизируя  $R(a|x)$  на  $a$  эквивалентно максимуму  $\Pr(Y=a|X) \Rightarrow \arg\min_a R(a|x) = \arg\max_a \Pr(Y=a|X)$ , т.е. ул. модель оптимальная.

При выборе модели я выбрали так  $L(0,0) = L(1,1) = 0$ ,  $L(1,0) = l_1$ ,  $L(0,1) = l_0$ .

$$\text{D-tb } f^*(x) = \arg\max_{a \in \{0,1\}} \Pr(Y=a|x).$$

Для  $x$  будем считать все пары  $y, a$  равновероятными

$$R(0|x) = L(0,0) \Pr(Y=0|x) + L(0,1) \Pr(Y=1|x) = l_0 \cdot \Pr(Y=0|x) + l_0 \Pr(Y=1|x) = l_0 \Pr(Y=1|x).$$

$$\text{если } a=1: R(1|x) = L(1,0) \Pr(Y=0|x) + L(1,1) \Pr(Y=1|x) = l_1 \Pr(Y=0|x) + 0 \cdot \Pr(Y=1|x) = l_1 \Pr(Y=0|x).$$

$$f^*(x) = \begin{cases} 0, & \text{если } l_0 \Pr(Y=1|x) < l_1 \Pr(Y=0|x), \\ 1, & \text{иначе.} \end{cases}$$

Установим и проверим условие, при котором

$$l_0 \Pr(Y=1|x) < l_1 (1 - \Pr(Y=1|x)) \Leftrightarrow (l_0 + l_1) \Pr(Y=1|x) < l_1 \Leftrightarrow$$

$$\Leftrightarrow \Pr(Y=1|x) < \frac{l_1}{l_0 + l_1}. \text{ Доказываем } a=1 \text{ корр. } \Pr(Y=1|x) > \frac{l_1}{l_0 + l_1}$$

$$f^*(x) = \arg\min_{a \in \{0,1\}} R(a|x) = \arg\min_{a \in \{0,1\}} (\alpha \Pr(Y \neq a|x)) = \arg\max_{a \in \{0,1\}} (\alpha \Pr(Y=a|x)),$$

т.е.  $\Pr(Y \neq a|x) = (\alpha (1 - \Pr(Y=a|x)))$  и минимизируем это соо. на  $a$  с крит. максимизацией  $(\alpha \Pr(Y=a|x))$ . \*

139

$$R(x) = E_X [E[\ell_{\text{HOD}}(Y|X)]]$$

т.к. биномияльное распределение по всем  $x$ , а  $P(X)$  можно выразить через  $f^*(x)$ , то оптимизи:

$$f^*(x) = \arg \min_{a \in \{1, \dots, K\}} R(a|x), \text{ где } R(a|x) - \text{ риск}$$

Возьмем  $R(a|x) = E[\ell_{\text{HOD}}(Y|X=x)]$ , т.к.  $Y$  принимает  $1, \dots, K$  различн.

$$R(a|x) = \sum_{y=1}^K \text{lag} \Pr(Y=y|X=x).$$

- логистическое правило же производит вероятн.

Если  $\text{lag} = \begin{cases} 0, & a=y \\ 1, & a \neq y \end{cases}$ , тогда  $R(a|x) = \sum_{y \neq a} \Pr(Y=y|X=x) = 1 - \Pr(Y=a|X=x)$ .

Минимизация по  $a$  эквив:  $f^*(x) = \arg \max_a \Pr(Y=a|X=x)$ , это есть МАР классификатор.

Итак  $f^*(x) = \arg \min_{a \in \{1, \dots, K\}} \sum_{y=1}^K \text{lag} \Pr(Y=y|X=x)$  и это оправдано минимизацией

$$f^*(x) = \arg \min_a E[\text{lag}|X=x].$$

N35

$$L(y, \hat{y}) = (\hat{y} - y)^2 \quad R(f^*) - ?$$

Для фиксированного  $x$  оптимизация  $\hat{y}(x) = \int (y - c)^2 p_{Y|X}(y|x) dy$ . Но вклад каждого  $y$  в это значение пропорционально  $(y - c)^2$ , где пропорционально  $c$  вспомогательное значение  $0$ .

$$(Y - c)^2 = Y^2 - 2cY + c^2, \quad g(c) = E[Y^2|X=x] - 2c E[Y|X=x] + c^2.$$

$E[Y^2|X=x]$  - константа по  $c$ .

$$g'(c) = -2 E[Y|X=x] + 2c = 0 \Rightarrow c = E[Y|X=x].$$

$$g''(c) = 2 > 0 \text{ значит минимум. } \Rightarrow f^*(x) = E[Y|X=x].$$

$$\text{Также } R(f^*) = E[(Y - f^*(x))^2] = E[(Y - E[Y|X])^2].$$

$$E[(Y - E[Y|X])^2] = E[\text{Var}(Y|X)] = E[Y^2] - E[E[Y|X]^2].$$

N36

$$L(y, \hat{y}) = |y - \hat{y}| \text{ называется } f^*(x) = \text{median}(Y|X=x).$$

$$\text{Задача максимизации по } c \text{ или медианы } g(c) = E[|Y - c| | X=x] = \int |y - c| p_{Y|X}(y|x) dy.$$

Найдем с минимальизирующее  $g(c)$ .

$$\text{Субдифференциал по } c: \frac{d}{dc} |y - c| = \begin{cases} -1, & y > c \\ (-1, 1), & y = c \\ 1, & y < c \end{cases} \text{ Тогда субградиент } G(c) \text{ для } g(c):$$

$$G(c) = E[\text{sign}(c - Y) | X=x] = \Pr(Y < c | X=x) - \Pr(Y > c | X=x),$$

минимизирует  $g(c)$ , если  $0 \in \partial g(c)$ , т.е. если  $\Pr(Y < c | X=x) \leq \frac{1}{2}$

и  $\Pr(Y > c | X=x) \geq \frac{1}{2}$ , где  $c$  - ул. медиана равн.  $Y|X=x$ .

Для шир. расп.  $\Pr(Y \leq c | X=x) = 1/2$ .

Если сдвигают  $c$  на  $\epsilon > 0$ :  $g(c+\epsilon) - g(c) \approx \epsilon (\Pr(Y < c | X=x) - \Pr(Y > c | X=x))$